# Rapport de Projet

Komlan Jean-Marie DANTODJI

Data Analysis et Text Mining

1- Text Processing and Transformation
Supposons on a la liste de document suivant à transformer:

Il s'agit de trouver un vocabulaire et de trouver une fréquence d'apparition de chaque mot du vocabulaire dans chaque document.

```
Vocabulaire:
['and', 'good', 'is', 'long', 'movie', 'not', 'scary', 'slow', 'spooky', 'this', 'very']
```

## Etape 1:

Dans chaque document déterminer le nombre d'occurrence de chaque élément du vocabulaire. Ainsi on se retrouve avec la matrice après passage de la fonction : def CountVectorizerOwn(all documents)

```
In [46]: data = CountVectorizerOwn(data)
data
Out[58]:
```

	and	good	is	long	movie	not	scary	slow	spooky	this	very
0	1.0	0.0	1.0	1.0	1.0	0.0	1.0	0.0	0.0	1.0	1.0
1	1.0	0.0	2.0	0.0	1.0	1.0	1.0	1.0	0.0	1.0	0.0
2	1.0	1.0	1.0	0.0	1.0	0.0	0.0	0.0	1.0	1.0	0.0

Etape 2 : Réduction de discrimination entre les mots d'un document Les mots fréquemment employé dans un document aura plus de chance d'être représenté que

les autres. Pour cela il faut diviser chaque occurrence par le nombre total de mots dans le dossier.

```
In [47]: data = TfidfTransformerOwn(data)
    data
```

Réduction de discrimination au sein du même document :

$$Tf\_d\_un\_mot = \frac{nombre\_occurence\_d\_un\_mot\_dans\_un\_document}{nombre\_total\_de\_mots\_dans\_document}$$



Réduction de discrimination dans l'ensemble des documents :

Ceci permet de réduire la fréquence d'apparition des mots les plus courent comme « is », « the ».

$$Idf\_d\_un\_mot = Tf\_d\_un\_mot * log (\frac{nombre\_de\_document\_total}{nombre\_de\_doc\_qui\_contiennent\_le\_mot})$$
Out [137]:
$$\frac{\text{and good is long movie not scary slow spooky this very}}{\textbf{0} 0.0 0.00000 0.0 0.06816} 0.0 0.00000 0.025156 0.00000 0.00000 0.0 0.06816}$$

$$\frac{\text{1} 0.0 0.00000 0.0 0.00000}{\text{1} 0.000000 0.0 0.00000} 0.0 0.05964 0.022011 0.05964 0.00000 0.0 0.00000}$$

0.0 0.00000 0.000000 0.00000 0.07952

0.0 0.00000

Dans le cas de la donnée de 20 Newsgroup dataset,

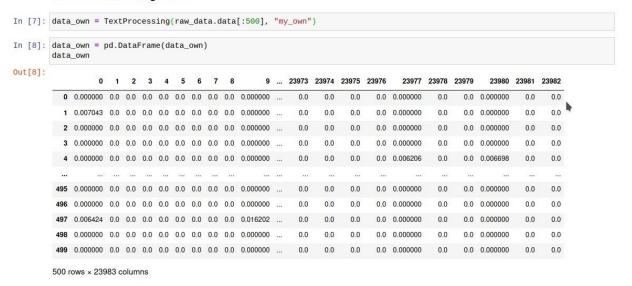
0.0 0.07952 0.0 0.00000

J'ai choisie les documents concernant quatre thèmes notamment :

["talk.politics.misc", "soc.religion.christian", "comp.os.ms-windows.misc", "rec.sport.baseball"]

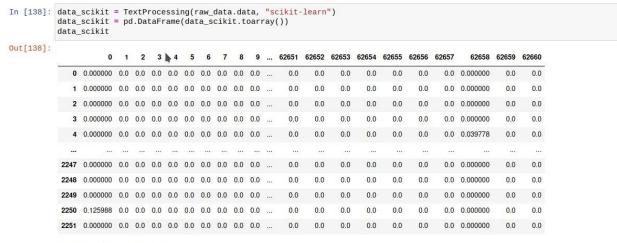
• Data présentant les features après traitement avec mon algorithme : J'ai choisie les 500 premiers documents à cause de la capacité de ram et de calcule de mon système.

#### Dataset with Own algorithm



• Data présentant les features après traitement de Scikit-Learn

## Dataset Scikit-learn algorithm



2252 rows x 62661 columns

## 2- Analyse de données

Caractéristiques des données :

Données null ou non NaN

## 2- Analysis of the dataset

```
In [10]: data_scikit.isnull().sum()
Out[10]: 0
         2
                  0
                  0
         23940
         23941
         23942
         23943
         23944
         Length: 23945, dtype: int64
In [11]: data_scikit.isna().sum()
Out[11]: 0
                  0
         2
                  0
         3
                  0
         23940
                  0
         23941
                  0
         23942
         23943
         23944
         Length: 23945, dtype: int64
```

Informations statistiques :

#### . Show some statistics on the Data In [12]: data\_scikit.describe() Out[12]: $0.003981 \quad 0.001431 \quad 0.000017 \quad 0.000056 \quad 0.000079 \quad 0.000056 \quad 0.000180 \quad 0.000108 \quad 0.000255 \quad 0.000255 \quad \dots$ 0.000014 2.592540e-07 $0.043405 \quad 0.011500 \quad 0.000382 \quad 0.001255 \quad 0.001761 \quad 0.001255 \quad 0.002878 \quad 0.002404 \quad 0.004038 \quad 0.004038 \quad \dots \quad 0.000320 \quad 5.797097e-06$ std 50% 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.00000 0.000000 ... 0.000000 0.000000e+00 $0.000000 \quad 0.000000 \quad \dots \quad 0.000000 \quad 0.0000000 \quad \dots \quad 0.000000 \quad 0.000000 \quad \dots \quad 0.000000 \quad 0.000000 \quad \dots \quad 0.0000000 \quad 0.000000 \quad \dots \quad 0.000000 \quad 0.0000000 \quad \dots \quad 0.000000 \quad \dots \quad 0.0000000 \quad \dots \quad 0.000000 \quad \dots \quad 0.0000000 \quad \dots \quad$ 75% 0.928060 0.196861 0.008539 0.028061 0.039375 0.028061 0.052342 0.053760 0.066519 0.066519 ... 0.007151 1.296270e-04 8 rows × 23945 columns

## Matrice de corrélation :

Pour la matrice de corrélation mon PC mets beaucoup de temps à faire les calculs de la matrice 23936x23936 éléments.

## 3- Machine Learning

Pour l'apprentissage, j'ai testé quatre modeles :

- Linear regression
- K-Near Neaghbor
- Support Vector Machine
- Decision Tree

Modeles	Linear	SVM	KNN	Decision Tree	
	Regression				
Score(scikit-	0	0.78	0.78	0.57	
Learn data)					
Score(Data on	0	0.47	0.47	0.56	
my Algorithm)					

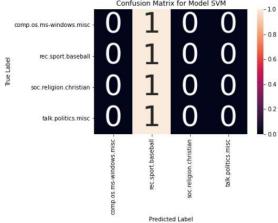
On remarque pour la prédiction de Linear regression, que un seul feature ne peut pas prédire l'autre à cause du nombre de feature très élevé (23938 features)

-Les autres scores sont aussi mauvais à cause de l'échantillon de donnée non représentatif. (500 considéré), par contre la donnée de scikit-learn étant plus représentatif, on note une amélioration de score du coté de SVM et KNN.

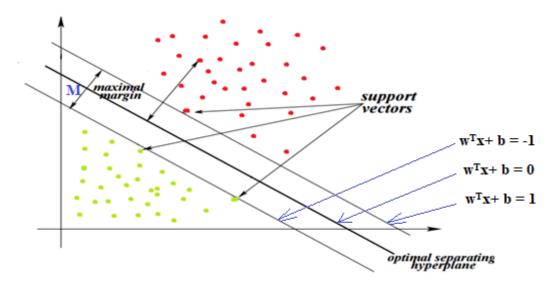
```
In [149]: X = data_scikit
           y = raw_data.target
          X_train, X_test, y_train, y_test = train_test_split(X, y, train_size=0.8, test_size=0.2, random_state=42)
In [150]: #KNN
           knn_clf = KNeighborsClassifier(n_neighbors=5)
           knn_clf.fit(X_train, y_train)
           predicted = knn_clf.predict(X_test)
           score = np.sum(predicted == y_test) / len(y_test)
           print("Score ", score)
           Score 0.7849223946784922
In [151]: #SVM
           from sklearn.svm import SVC
           svm_clf = SVC(gamma='auto')
svm_clf.fit(X_train, y_train)
predictions = svm_clf.predict(X_test)
           score = np.sum(predicted == y_test) / len(y_test)
           print("Score ", score)
           Score 0.7849223946784922
In [152]: #Decision Tree
           from sklearn.tree import DecisionTreeClassifier
           dt_clf = DecisionTreeClassifier(max_depth=2)
           dt_clf.fit(X_train, y_train)
           predicted = dt_clf.predict(X_test)
           score = np.sum(predicted == y_test) / len(y_test)
          print("Score ", score)
           Score 0.5764966740576497
```

#### 4- Visualisation

```
predict_train_svm = svm_clf.predict(X_train)
In [157]: def plot_confusion_matrix(cm, classes=None, title=None):
              if classes is not None
                  sns.heatmap(cm, xticklabels=classes, yticklabels=classes, vmin=0, vmax=1, annot=True, annot_kws={'size':50})
              else:
                  sns.heatmap(cm, vmin=0, vmax=1)
              plt.title(title)
              plt.xlabel("Predicted Label")
              plt.ylabel("True Label")
In [158]: from sklearn.metrics import accuracy_score, confusion_matrix, classification_report, r2_score
          cm_svm = confusion_matrix(y_train, predict_train_svm)
          cm_svm_norm = cm_svm/cm_svm.sum(axis=1)[:, np.newaxis]
          classes = raw_data.target_names
          plot_confusion_matrix(cm_svm_norm, classes, title="Confusion Matrix for Model SVM")
                                   Confusion Matrix for Model SVM
                                                                   -1.0
             comp.os.ms-windows.misc
```



## 5- Détails théoriques : Support Vector Machine



L'objectif du SVM est de déterminer l'hyperplan qui sépare une classe des autres avec une marge maximale M.

Soit  $x_0$  et  $x_1$  deux vecteurs supports aux deux extrémités et

$$Soit \ l'hyperplant \ (P) : w^Tx + b = 0, \quad w \in \mathbb{R}^p, \quad b \in \mathbb{R}$$

$$Soit \ f(x) = w^Tx + b$$

$$y_i \in \{-1,1\}, \quad i \in \{0,n\}$$

$$\left\{ \begin{array}{l} if \ y_i = 1 => \ w^Tx + b \geq 1 \ (top \ side) \\ if \ y_i = -1 => \ w^Tx + b \leq -1 \ (bottom \ side) \end{array} \right. \Rightarrow y_i(w^Tx + b) \geq 1$$

$$M = d(x_0, P) + d(x_1, P) = \frac{|w^Tx_0 + b|}{||w||} + \frac{|w^Tx_1 + b|}{||w||} = \frac{|1|}{||w||} + \frac{|-1|}{||w||} = \frac{2}{||w||}$$

$$\left\{ \begin{array}{l} Max \ (M) = Max(\frac{2}{||w||}) \\ on \ y_i(w^Tx + b) \geq 1 \end{array} \right. \Rightarrow \left\{ \begin{array}{l} Min \ (||w||) \\ on \ y_if(x) \geq 1 \end{array} \right.$$

**Minimum Cost of function** 

$$J = \gamma ||w||^2 + \frac{1}{n} \sum_{i=1}^n Max(0, 1 - y_i(w^T x + b)) = \gamma ||w||^2 + \frac{1}{n} \sum_{i=1}^n Max(0, 1 - y_i f(x))$$

$$Max(0, 1 - y_i f(x)) = \begin{cases} 0 & \text{if } y_i f(x) \ge 1 \\ 1 - y_i f(x) & \text{else} \end{cases}$$

## **Gradients:**

if 
$$y_i f(x) \ge 1$$
:

$$\frac{dJ_i}{dw_k} = 2\gamma w_k \; ; \qquad \frac{dJ_i}{db} = 0$$

Else:

$$\frac{dJ_i}{dw_k} = 2\gamma w_k - y_i. x_i; \qquad \frac{dJ_i}{db} = y_i$$

**Update:** 

$$\begin{cases} w = w - \gamma \frac{dJ_i}{dw_k} \\ b = b - \gamma \frac{dJ_i}{db} \end{cases}$$