

# Off-Line Handwritten Character Recognition System Using Support Vector Machine

Komlan Jean-Marie DANTODJI  
*Université Paris Vincennes St-Denis*  
*M1 Big Data*

November 26, 2020

# Contents

<b>1</b>	<b>Introduction à la méthode du SVM : Support Vector Machine</b>	<b>2</b>
1.1	Linéarité séparable . . . . .	2
1.2	Linéarité inséparable . . . . .	3
<b>2</b>	<b>Etapes de prétraitement:</b>	<b>4</b>
<b>3</b>	<b>Extraction des caractéristiques</b>	<b>5</b>
<b>4</b>	<b>Model de SVM</b>	<b>6</b>
<b>5</b>	<b>Synthèse et Conclusion</b>	<b>7</b>
<b>6</b>	<b>Références</b>	<b>7</b>

# 1 Introduction à la méthode du SVM : Support Vector Machine

Proposé par Boser, Guyon, et Vapnik en 1992, SVM est une technique de classification linéaire et non linéaire.

## 1.1 Linéarité séparable

SVM est un modèle d'apprentissage supervisé basé sur la détermination d'un hyperplan qui sépare les données d'une classe des autres classes.




Figure 1: Détermination de l'hyperplan

L'objectif du SVM est de déterminer l'hyperplan qui sépare une classe des autres avec une marge maximale M.

Soit  $x_0$  et  $x_1$  deux vecteurs supports aux deux extrémités et Soit l'hyperplan

$$(P) : w^T x + b = 0$$

$$M = d(x_0, P) + d(x_1, P) = \frac{|w^T x_0 + b|}{\sqrt{w^T w}} + \frac{|w^T x_1 + b|}{\sqrt{w^T w}}$$

$$= \frac{|1|}{\sqrt{w^T w}} + \frac{|-1|}{\sqrt{w^T w}} = \frac{2}{\sqrt{w^T w}}$$

Maximiser M revient à minimiser

$$\frac{\sqrt{w^T w}}{2} = \frac{\|w\|}{2}$$

## 1.2 Linéarité inséparable

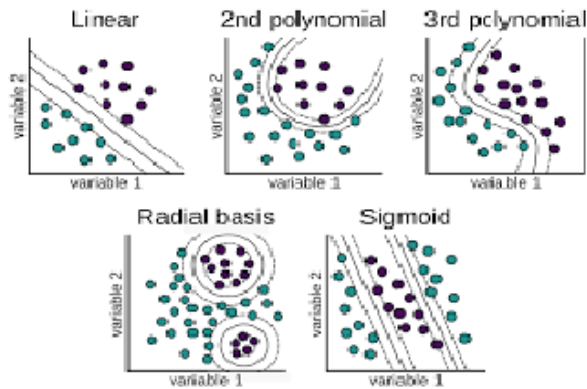


Figure 2: Inséparabilité linéaire : <https://www.r-bloggers.com/2019/10/support-vector-machines-with-the-mlr-package/>

Dans ces cas d'inséparabilité linéaire on peut utiliser des fonctions de kernel notamment :

Kernel linéaire:

$$K(X_i, X_j) = x_i^T x_j$$

Kernel Polynomial:

$$K(X_i, X_j) = (\gamma x_i^T x_j + r)^d$$

Kernel Radial:

$$K(X_i, X_j) = e^{\gamma(x_i - x_j)^2}$$

Kernel Sigmoid:

$$K(X_i, X_j) = \tanh(\gamma x_i^T x_j + r)$$

## 2 Etapes de prétraitement:

Pour implémenter ce model on s'est servi des données de la base de données de CENPARMI, CEDAR et MNIST). Une première étape est le prétraitement de l'image contenant le texte manuscrit permettant une bonne extraction des caractéristiques.

Les différentes étapes de prétraitement :

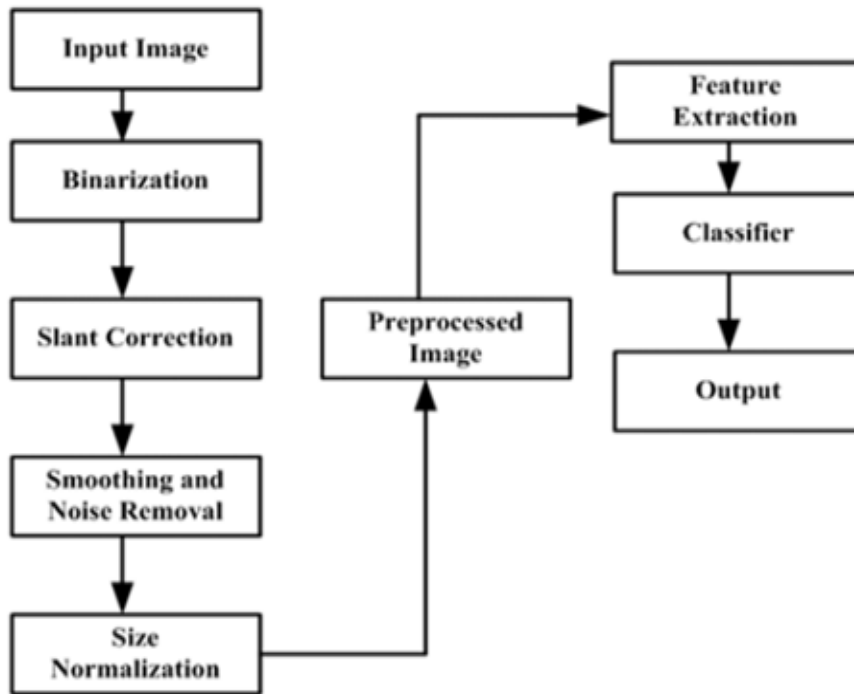


Figure 3: Etapes de prétraitement de l'image : <http://www.sciencepublishinggroup.com/j/ajnna>

- Binarization :

L'image est convertie en niveau de gris pour éviter les problèmes causés par les bruits nuisible à l'extraction des caractéristiques

- Slant Correction :  
Correction de l'inclinaison, Procéder à un repositionnement de l'image si elle n'est pas droite.
- Smoothing and Noise Removal :  
Polir et éliminer les bruits
- Size Normalization :  
Normaliser la taille des caractères pour avoir la même dimension.

### 3 Extraction des caractéristiques

Pour chaque caractère récupéré on a besoin des caractéristiques qui peuvent la représenter. Pour cela on distingue plusieurs méthodes d'extraction de caractéristique dont la méthode de Diagonal distance :




Figure 4: Méthode d'extraction diagonale:  
<https://www.researchgate.net/figure/Procedure-for-extracting-feature-from-the-characters>

## 4 Model de SVM

Pour avoir plus une meilleure classification on utilise le Kernel polynomial pour avoir une meilleure séparation des classes de chaque caractère.

Les différents étapes de SVM :

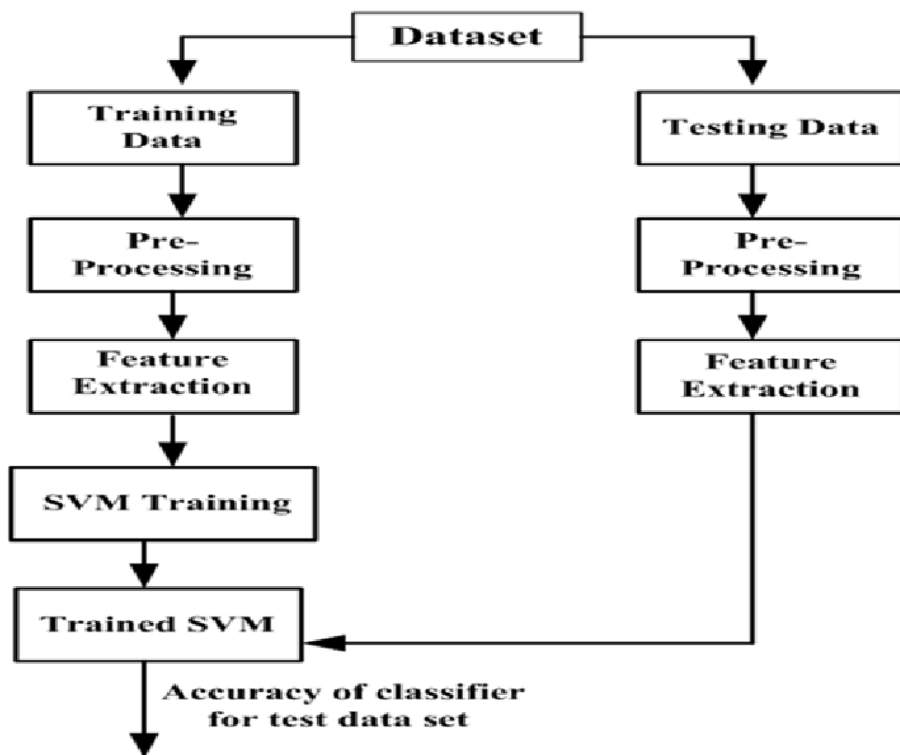


Figure 5: Etapes de SVM: <https://www.researchgate.net/figure/Different-stages-of-SVM-classification>

## 5 Synthèse et Conclusion

La précision de la méthode de SVM en l'appliquant à la base de donnée CED AR CDROM est définie dans le tableau suivant :

*Table 1. % Accuracy with SVM classifier.*

<b>Classifier</b>	<b>% Accuracy for digits</b>	<b>% Accuracy for capital alphabet</b>	<b>%Accuracy for small alphabet</b>
SVM	97.16	95.74	92.19

Figure 6: <https://www.researchgate.net/publication/323112207Off-Line-Handwritten-Character-Recognition-System-Using-Support-Vector-Machine>

## 6 Références

[1] Gauri Katiyar, Ankita Katiyar, Shabana Mehfuz ont écrit la revue Off-Line Handwritten Character Recognition System Using Support Vector Machine publié dans le journal American Journal of Neural Networks and Applications le 13 décembre 2017.